PUC-Rio
INF1038 · Trabalho 1

Previsão de doença cardíaca

Base *Heart Failure Prediction* (Kaggle)

Aviv Cozer Aharon · 2211745
Gustavo Maia Riedel · 2210375

Outubro de 2026

1. A base

A ideia do trabalho é prever se um paciente tem doença cardíaca usando exames simples. A gente escolheu a base *Heart Failure Prediction* do Kaggle, que junta cinco bases antigas da UCI e tem 918 pacientes com 11 atributos: idade, sexo, tipo de dor no peito, pressão, colesterol, glicemia, ECG em repouso e alguns dados do teste de esforço (frequência máxima, angina no exercício, `Oldpeak` e inclinação do segmento ST). O alvo é `HeartDisease` (1 = doente).

Achamos que valia a pena usar: não tem valores nulos nem linhas repetidas, e as classes estão bem equilibradas (508 doentes e 410 normais). O único problema sério é que 172 pacientes (19%) estão com colesterol igual a zero e um está com pressão zero, o que é impossível. Na prática isso é dado faltante.

2. Limpeza

Uma coisa curiosa: dos pacientes com colesterol zero, 88% são doentes, contra 48% no resto. Fomos ver e quase todos esses zeros vêm da base da Suíça, que não mediu colesterol e tinha muito doente. Então o zero não diz nada sobre o colesterol, só sobre de onde o paciente veio.

O que fizemos: tiramos a linha com pressão zero e trocamos os zeros de colesterol pela mediana (calculada só no treino, dentro do pipeline). Não quisemos criar uma coluna "colesterol faltando", porque aí o modelo ia aprender essa coincidência da coleta. Os outliers (pressão até 200, colesterol até 603) e os poucos `Oldpeak` negativos fazem sentido clinicamente, então deixamos.

3. Análise exploratória

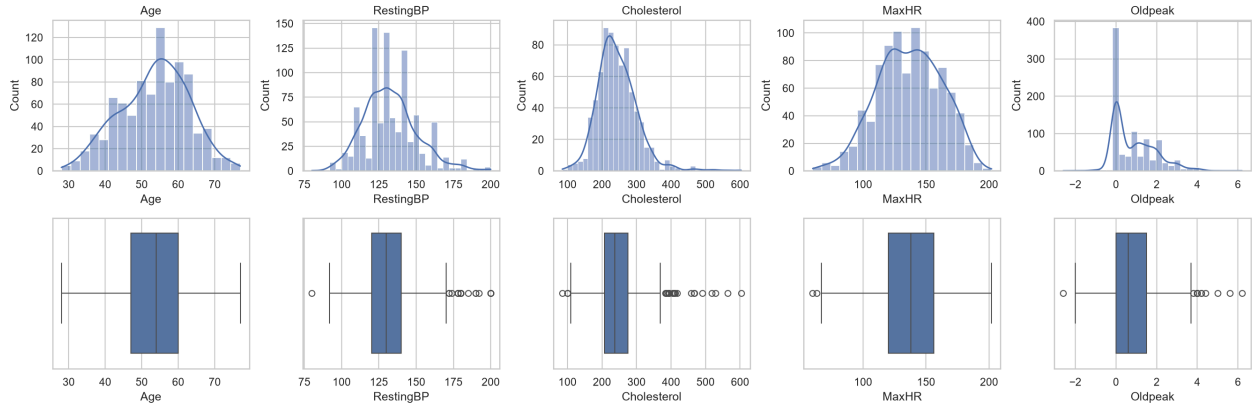


Figura 1. Distribuição dos atributos numéricos.

Nenhum atributo numérico é normal (teste de Shapiro), então usamos testes não paramétricos. Colesterol e `Oldpeak` são bem assimétricos. Um ponto que limita o trabalho: 79% dos pacientes são homens.

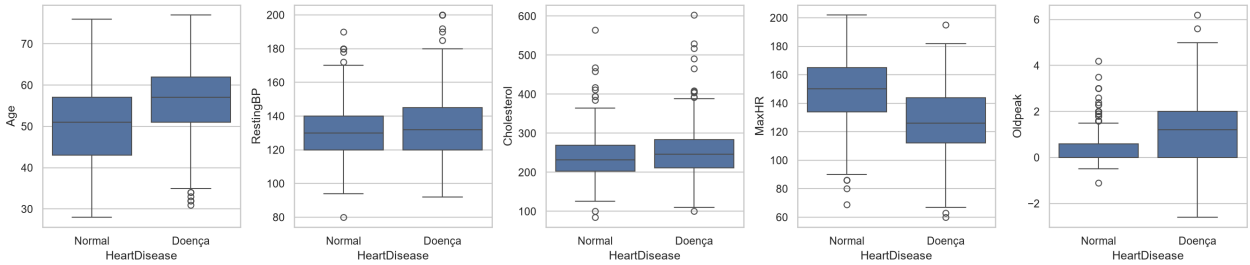


Figura 2. Atributos numéricos separados por classe.

Tabela 1. Força da associação dos atributos categóricos com a doença.

Atributo	V de Cramér
ST_Slope	0,62
ChestPainType	0,54
ExerciseAngina	0,49
Sex	0,30
FastingBS	0,27
RestingECG	0,11

O que mais separa doente de não doente é o teste de esforço: ST plano ou descendente, angina no exercício, `Oldpeak` alto e frequência máxima baixa. O que mais surpreendeu foi o tipo de dor: os pacientes **sem dor** no peito são os que mais têm doença. Parece estranho, mas existe a isquemia silenciosa, e também quem faz esses exames sem sintoma provavelmente foi mandado por outro motivo.

Pressão e colesterol deram "significativos" no teste estatístico, mas a diferença é mínima (mediana de colesterol 232 contra 246, por exemplo). Com quase mil pacientes, qualquer diferença pequena vira significativa.

4. Análise multivariada

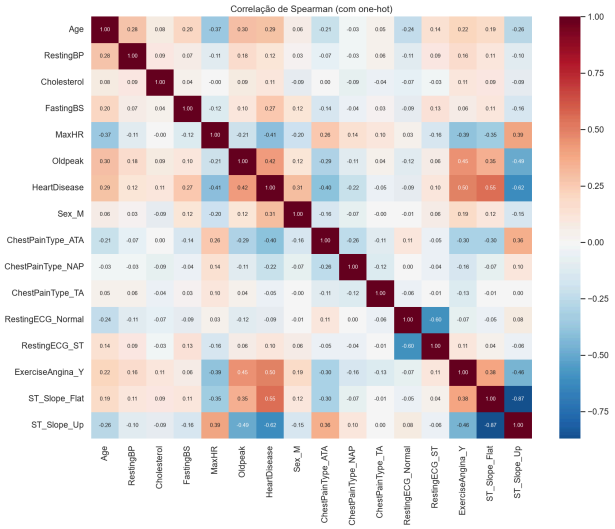


Figura 3. Correlação de Spearman.

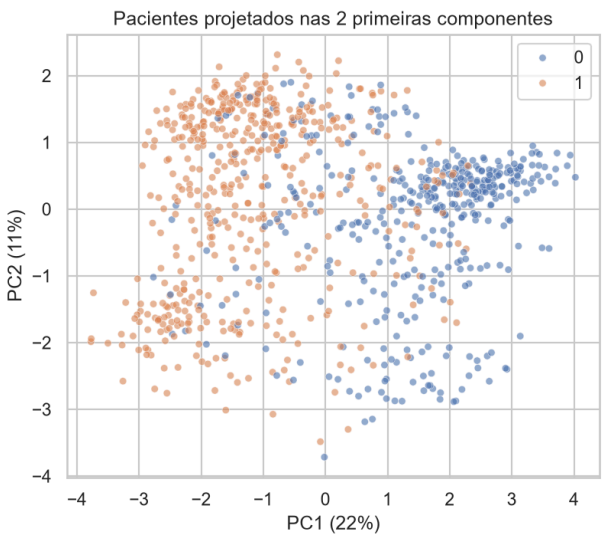


Figura 4. Pacientes no PCA (1 = doente).

Depois do one-hot ficamos com 15 atributos. As variáveis do teste de esforço são correlacionadas entre si, mas não tem nada muito redundante (o VIF só chega perto de 5 nas duas dummies de `ST_Slope`). No PCA dá para ver as duas classes quase separadas, com uma parte misturada no meio. Daí já dava para esperar duas coisas: que um modelo linear fosse funcionar bem, e que a acurácia ficasse perto de 85%, não 99%.

5. Seleção de atributos

Separamos 80% para treino e 20% para teste, e o teste só foi usado no final. Testamos os métodos vistos em aula: filtro (ANOVA), wrapper (RFE com Regressão Logística), embutido (Logística com L1) e PCA. Tudo foi avaliado com validação cruzada (5 folds, repetida 10 vezes).

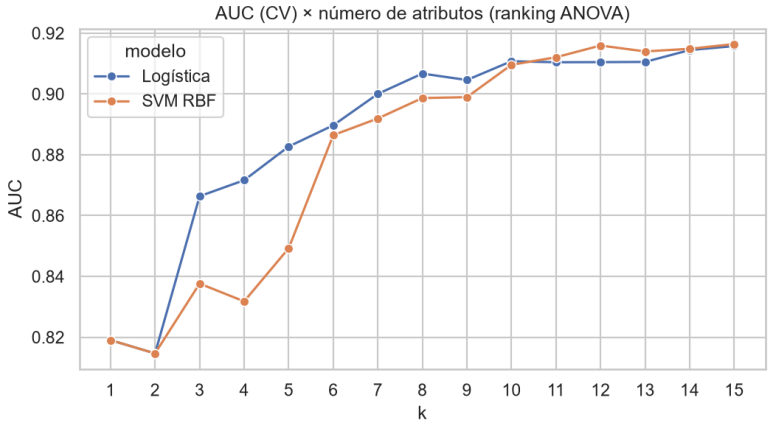


Figura 5. AUC conforme aumenta o número de atributos.

Tabela 2. Comparação dos métodos (AUC na validação cruzada).

Método	Logística	SVM RBF
Todos (15)	0,916	0,916
Filtro ANOVA (10)	0,913	0,909
RFE (12)	0,917	0,914
L1	0,916	0,915
PCA (11 comp.)	0,912	0,914

Deu tudo praticamente igual. Com só 3 atributos já chega em 0,87 de AUC, e depois de uns 10 a curva para de subir. Como nenhum método ganhou, escolhemos pelo mais simples: os 12 do RFE, que tiram idade, pressão e colesterol. Os outros métodos também apontavam esses três como os menos úteis. O PCA ficou de fora porque não dá para interpretar as componentes.

A idade foi o caso mais interessante, porque sozinha ela é bem significativa. Só que pacientes mais velhos já têm frequência máxima menor e mais angina, então quando o teste de esforço está no modelo a idade não acrescenta nada.

6. Modelos

Regressão Linear. Mesmo não sendo feita para isso, usando corte em 0,5 ela acertou 87,5% no teste. O problema é que 30 das 184 previsões saíram fora de [0, 1], então não dá para ler como

probabilidade. Por isso ela não é a escolha certa para classificação.

Regressão Logística. Olhando os coeficientes, ser homem multiplica a chance de doença por uns 4,4, glicemia alta por 3,7 e angina no exercício por 2,3. Quem sente algum tipo de dor tem bem menos chance que o assintomático (odds ratio de 0,17). O ECG em repouso não fez diferença.

SVM. Testamos SVM linear e com kernel RBF, ajustando os parâmetros com GridSearch. Na validação cruzada os três modelos ficaram empatados (AUC entre 0,916 e 0,923). O SVM RBF escolheu um gamma bem pequeno, que deixa a fronteira quase reta, ou seja, ele mesmo "concluiu" que o problema é linear.

7. Resultados no teste

Tabela 3. Resultados no conjunto de teste (184 pacientes).

Modelo	Acurácia	Recall	AUC
Regressão Logística	0,870	0,892	0,937
SVM linear	0,853	0,882	0,936
SVM RBF	0,853	0,892	0,935

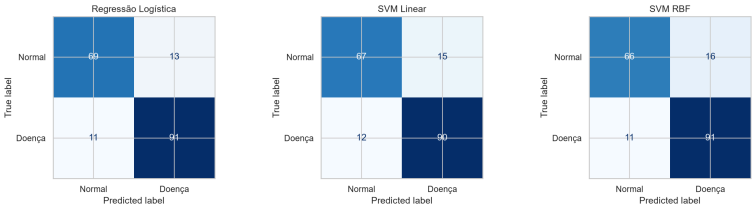


Figura 6. Matrizes de confusão.

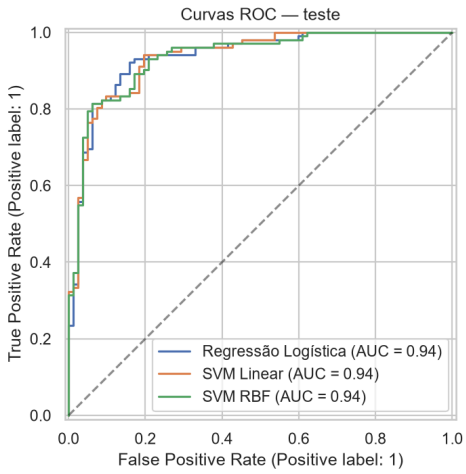


Figura 7. Curvas ROC.

A Logística foi um pouco melhor, mas a diferença é de 3 pacientes, então é basicamente empate. Ficamos com ela por ser a mais simples e a mais fácil de explicar. O resultado no teste foi parecido com o da validação cruzada, então não parece ter overfitting.

Como em saúde é pior deixar passar um doente do que pedir um exame a mais, baixamos o limiar de 0,5 para 0,35. Com isso os falsos negativos caíram de 11 para 6 (recall de 89% para 94%) e a acurácia continuou em 87,5%.

8. Conclusão

Os resultados foram bons porque os dados do teste de esforço e o tipo de dor têm muita relação com a doença, e as classes são quase separáveis por uma reta. Não passou muito de 87% porque tem um grupo de pacientes (os erros do modelo) em que doentes e saudáveis têm exames parecidos. Os doentes que o modelo errou, por exemplo, tinham teste de esforço praticamente normal. Para acertar

esses casos seriam precisos exames que a base não tem. Também pesa contra a base ser pequena, misturar cinco hospitais e ter quase só homens.

No fim, o que aprendemos é que nesses dados o teste de esforço diz muito mais do que colesterol, pressão ou idade, e que um modelo simples como a Regressão Logística já resolve tão bem quanto o SVM.